

ラビット・チャレンジ

<実装演習レポート 応用数学>

メールアドレス: mtop.jp@gmail.com

受講者名: 山崎 英和

受講種別: ラビット・チャレンジ

## <第一章 線形代数>

### 要点まとめ

#### ■固有値、固有ベクトルの求め方

正方行列 $A$ について、

$$A\vec{x} = \lambda\vec{x}, \quad \vec{x} \neq 0 \quad \dots (1)$$

のとき、 $\lambda$ を $A$ の固有値といい、 $\vec{x}$ を $\lambda$ に関する固有ベクトルという

#### 固有値を求める公式

正方行列 $A$ について、

$$\det(A - \lambda I) = 0 \quad \dots (2)$$

のとき、 $\lambda$ は行列 $A$ の固有値である。

ここで、

$\det()$ : 行列式

$I$ : 単位行列

#### 固有ベクトルの求め方

(1)の式に、(2)で求めた固有値を代入し、等式が成り立つような $\vec{x}$ を固有ベクトルという。  
固有値の数だけ、それに対する固有ベクトルが存在する

#### ■固有値分解

正方行列 $A$ が固有値 $\lambda$ 、固有ベクトル $V$ を持つとき、

$$A = V\Lambda V^{-1} \quad \dots (3)$$

と変形することを固有値分解という。

ただし、 $\Lambda$ は固有値 $(\lambda_1, \lambda_2, \dots)$ を対角線上に並べた式

$V$ は固有ベクトル $(\vec{v}_1, \vec{v}_2, \dots)$ である

#### ■特異値・特異ベクトル、特異値分解

正方行列でない $M$ に対して、以下を満たす単位ベクトル $\vec{u}, \vec{v}$ がある場合、

$$M\vec{v} = \sigma\vec{u} \quad \dots (1)$$

$$M^t\vec{u} = \sigma\vec{v} \quad \dots (2)$$

以下のように特異値分解が可能。

$$M = USV^{-1} \dots (3)$$

ここで、 $M$ は  $m \times n$  の行列、 $U$ は  $m \times r$  の直行行列、 $S$ は  $r \times r$  の特異値の対角行列、 $V$ は  $r \times n$  の直行行列。

(1)と(2)を行列で表すと以下となる。

$$\begin{aligned} MV &= US, & M^T U &= VS^T \\ \Rightarrow M &= USV^{-1}, & M^T &= VS^T U^{-1} \end{aligned}$$

これらの積は、

$$\begin{aligned} MM^T &= USV^{-1}VS^T U^{-1} = USS^T U^{-1} \\ M^T M &= VS^T U^{-1}USV^{-1} = VS^T SV^{-1} \end{aligned}$$

つまり、 $MM^T$ を固有値分解すれば、その左特異ベクトル $U, V$ と特異値 $S$ の2乗が求まる。

## <第二章 確率・統計>


### 要点まとめ

#### ■条件付き確率

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

#### ■ベイズの定理

$$\underline{P(A)P(B|A)} = P(B)P(A|B) = P(A \cap B)$$



#### ■期待値:

##### 1. 確率変数 $X$ が離散的な確率の期待値

$$E(X) = \sum_{k=1}^n x_k \times p_k$$

##### 2. 確率変数 $X$ が連続的な確率の期待値

$$E(X) = \int x f(x) dx$$

#### ■分散・標準偏差・共分散

##### 1. 確率変数 $X$ の期待値を $E(X) = \mu$ とすると、 $X$ の分散 $V(X)$ は、

$$V(X) = E[(X - \mu)^2] = E(X^2) - (E(X))^2$$

##### 2. 確率変数 $X$ の標準偏差 $\sigma(X)$ は、

$$\sigma(X) = \sqrt{V(X)}$$

##### 3. 確率変数 $X$ と $Y$ の期待値をそれぞれ $E(X) = \mu_x, E(Y) = \mu_y$ とすると、

$X$ と $Y$ の共分散 $Cov(X, Y)$ は、

$$Cov(X, Y) = E[(X - \mu_x)(Y - \mu_y)]$$

## ■確率分布

### 1. ベルヌーイ分布

確率変数 $X$ が0と1の2値を取るとき、1の出る確率を $p$ と置くと、次の式で表せる

$$P(x|p) = p^x(1-p)^{1-x}$$

### 2. 二項分布

確率変数 $X$ が0と1の2値を取るとき、 $n$ 回試行して $k$ 回1となる分布は、次の式で表せる

$$P(k|p, n) = {}_nC_k P(k|p) = \frac{n!}{k!(n-k)!} p^k (1-p)^{n-k}$$

### 3. ガウス分布

正規分布に従う確率変数 $X$ は、次の式で表せる


$$N(x, \mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

ここで、 $\mu$ は $E(X)$ 、 $\sigma^2$ は $V(X)$ 。

## ■母集団の推定

母集団に属する一部の集合を標本と呼ぶ。

標本から母集団のパラメータ(母平均、母分散など)を推定する。



## ■標本平均

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

→ 母平均 $\mu$ を推定

## ■標本分散

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

## ■不変分散

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

→ 母分散 $\sigma^2$ を推定

## <第三章 情報理論>

### 要点まとめ

#### ■自己情報量

$$I(x) = -\log(P(x))$$

#### ■シャノンエントロピー

$$\begin{aligned} H(x) &= E(I(x)) \\ &= -E(\log(P(x))) \\ &= -\sum P(x)\log(P(x)) \end{aligned}$$